

Reconocimiento de Patrones: Clasificación de Caracteres N, M, U, P y @

Vicente Ibacache - 21640785

1 de septiembre de 2026

1. Introducción y Motivación

El reconocimiento óptico de caracteres es un problema típico en el reconocimiento de patrones y ofrece un buen desafío para probar las técnicas de segmentación, extracción de descriptores geométricos y clasificación de caracteres.

En esta tarea se verá la clasificación de los siguientes cinco caracteres con propiedades geométricas distintivas: **N**, **M**, **U**, **P** y **@**. Los primeros tres no encierran agujeros y se diferencian por el número de trazos que cruzan el carácter horizontalmente, mientras que **P** y **@** sí encierran una región de fondo y se distinguen por su forma general (alargada vs. circular). Para la diferenciación de estos caracteres, se diseñó un pipeline de segmentación y un árbol de decisión simple, calibrado sobre un conjunto de entrenamiento, para así evaluar qué tan bien generaliza a un conjunto de testeo con mayor ruido y variabilidad en el *font* utilizado.

2. Desarrollo y Método

El sistema consiste en las siguientes cinco etapas: (1) Segmentación, (2) Limpieza de ruido, (3) Extracción de descriptores, (4) Clasificación por árbol de decisión y (5) Evaluación.

Segmentación: Cada imagen en escala de grises se binariza con el umbral de **Otsu** (`segment_otsu`). Como el fondo tiene textura ruidosa, se mantiene únicamente la componente conexa de mayor área (`keep_largest_blob`), eliminando la mayor parte del ruido.




Figura 1: Demostración de segmentación de Otsu con el carácter N

Descriptores. El área normalizada $a = A/A_f$ compara el área del carácter (A) con su área tras rellenar agujeros por flood-fill (`fill_holes`): $a \approx 1$ para N/M/U (sin agujeros) y $a < 1$ para P/@ (con agujero). La excentricidad de la región rellena (`measure.regionprops`) separa P (el cual generalmente tiene una forma alargada) de @ (el que tiene una forma achatada cercana a una circular). Los cruces de líneas de barrido (`max_scanline_crossings`), contados sobre la esqueletonización más un podado de ramas espurias (`skeletonize_binary + prune_skeleton_spurs`), separan N, M y U: 4 cruces $\Rightarrow$ M, 3 $\Rightarrow$ N, 2 $\Rightarrow$ U.

Cierre de brechas. Algunas fuentes del testeo (frecuente en la letra P) dejan discontinuidades

en el contorno que permiten que el flood-fill se filtre, ocultando el agujero. `close_gaps` aplica un cierre(dilatación + erosión, disco de radio r) antes de calcular el área normalizada.

Árbol de decisión. La siguiente figura resume `classify_character`. El umbral de área normalizada (0,95) y el de excentricidad (0,64, Figura 3) se calibraron sobre el conjunto de entrenamiento, buscando el punto de menor solapamiento entre las distribuciones de P y @.




Figura 2: Árbol de decisión de `classify_character`




Figura 3: Excentricidad de P y @ (entrenamiento).

3. Experimentos y Resultados

Se dispuso de 250 imágenes de entrenamiento y 125 de testeo (con 5 clases balanceadas). Se compararon los clasificadores `nm_method='skeleton'` y `nm_method='erosion'` con `closing_radius` 0 y 3 y se vio cual combinación era un mejor clasificador.

Conjunto	<code>nm_method='erosion'</code>	<code>nm_method='skeleton'</code>
$r = 0$	84,0 % (210/250)	94,0 % (235/250)
$r = 3$	84,0 % (210/250)	92,8 % (232/250)

Tabla 1: Exactitud global por conjunto y configuración de clausura.

De esta manera se eligió `nm_method='skeleton'` como el método más alineado con la realidad, pero se realizaron tests con `closing_radius = 0` y `closing_radius = 3` para su comparación con *fonts* más complejos.

Entrenamiento ($r=0$) exactitud=0.940						Testeo ($r=0$) exactitud=0.728						Testeo ($r=3$) exactitud=0.752								
Real	N	46	4	0	0	0	N	15	0	10	0	0	N	15	0	10	0	0		
	M	0	50	0	0	0	M	0	19	6	0	0	M	0	19	6	0	0		
	U	0	0	49	0	1	U	0	0	25	0	0	U	0	0	24	1	0		
	P	0	0	4	46	0	P	3	0	11	11	0	P	3	0	11	11	0		
	@	4	0	0	2	44	@	0	4	0	0	21	@	0	0	0	0	25		
		N	M	U	P	@			N	M	U	P	@			N	M	U	P	@
		Predicho							Predicho							Predicho				

Figura 4: Matrices de confusión: entrenamiento y testeo (sin y con clausura de brechas).

En entrenamiento el clasificador funciona bastante bien (M perfecta, 50/50); los pocos errores son confusiones puntuales entre clases vecinas del árbol ($N \leftrightarrow M$, $P \leftrightarrow U$, $@ \rightarrow N/P$). En testeo la exactitud cae notoriamente, con dos patrones sistemáticos: $N \rightarrow U$ (10/25, en ambas configuraciones) y $P \rightarrow U$ (11/25). El cierre de brechas sí ayuda a la clase @ (de 21/25 a 25/25), confirmando que `close_gaps` cumple su propósito frente a fuentes desgastadas, aunque no corrige la confusión N/U, que se origina en el descriptor de cruces de barrido, no en el área normalizada. Lo interesante también es que, a diferencia del set de entrenamiento, aquí $r = 3$ tiene una mayor exactitud que $r = 0$.

4. Conclusiones

El clasificador basado en descriptores geométricos simples (área normalizada, excentricidad, cruces de barrido) generaliza bien dentro del conjunto de entrenamiento (94,0%), pero pierde puntos porcentuales al pasar al conjunto de testeo (72,8–75,2%). Esta caída es de esperar ya que el conjunto de testeo tiene mucho más ruido de fondo y una variabilidad tipográfica mucho mayor que el de entrenamiento, y los umbrales del árbol se calibraron sólo con este último.

El caso más claro es la confusión sistemática $N \rightarrow U$: en varias fuentes de testeo la N se dibuja "pies anchos y una diagonal muy gruesa que, tras esqueletizar, produce un patrón difícil de distinguir del de una U. También ocurre que según algunos *fonts*, algunas N parecen, visualmente, una U rotada. La Figura 5 lo ilustra con ejemplos reales del conjunto de testeo: frente a una N limpia de entrenamiento, estas N muestran una silueta muy similar a la de una U genuina del mismo conjunto.




Figura 5: N de entrenamiento, tres N de testeo clasificadas como U y una U real de testeo.

De este análisis se desprenden tres observaciones finales:

- El enfoque de descriptores geométricos con umbrales fijos generaliza bien cuando la fuente y el ruido del testeo son similares a los del entrenamiento, pero es frágil frente a variaciones tipográficas fuertes como las del conjunto de testeo.
- El cierre de brechas (`close_gaps`) es efectivo para recuperar agujeros rotos por ruido o por fuentes desgastadas (mejora @ de 21/25 a 25/25 y la exactitud global de 72,8% a 75,2%),

pero no corrige la confusión N/U ni P/U, que dependen del descriptor de cruces de barrido, no del área normalizada.